ELEKTRİKLİ ARAÇ ŞARJ İSTASYONLARINDA DOLULUK TAHMİNİ

Mahmud Selman ŞAHİN – 241230008 | Ege Arhan YILDIZALKAN – 241230013

PROJE TANIMI

Elektrikli araçların yaygınlaşmasıyla birlikte şarj istasyonlarında yaşanan yoğunluğun önceden öngörülmesi, hem sürücülerin bekleme sürelerini azaltmak hem de istasyon işletmecilerinin enerji ve kapasite yönetimini kolaylaştırmak açısından kritik bir ihtiyaç haline gelmiştir. Bu proje; istasyonların geçmiş kullanım alışkanlıklarını, gün ve saat gibi takvim bilgilerini, hava koşullarını ve elektrik fiyatlarını dikkate alarak şarj noktalarının yakın gelecekteki doluluk durumunu tahmin eden akıllı bir sistem tasarımı sunmaktadır. Çalışma kapsamında farklı şehir ve ülkelerden toplanan gerçek kullanım verileri incelenerek, geliştirilen tahmin yöntemlerinin yalnızca tek bir bölgede değil, farklı kullanım alışkanlıklarına sahip farklı ortamlarda da ne kadar başarılı çalıştığı test edilmektedir. Böylece altyapı yöneticilerine ve araç sahiplerine anlık yoğunlukları yönetme ve planlama yapma imkânı tanıyan, gerçek hayata uyarlanabilir güvenilir bir karar destek altyapısı oluşturulması amaçlanmaktadır.

VERİ SETLERİ

1- UrbanEV: An open benchmark dataset for urban electric vehicle charging demand prediction. https://doi.org/10.5061/dryad.np5hqc04z

2- ACN-Data: Analysis and Applications of an Open EV Charging Dataset. https://doi.org/10.1145/3307772.3328313

3- Electric vehicle charging dataset with 35,000 charging sessions from 12 residential locations in Norway. https://doi.org/10.5281/zenodo.13896176

LİTERATÜR TARAMASI

1. **ACN-Data: Analysis and Applications of an Open EV Charging Dataset (2019) [1]:** Caltech ve JPL kampüslerindeki 30.000'i aşkın gerçek şarj oturumunu içeren açık veri setini sunmuş; oturum verilerinden doluluk ve yük profillerinin türetilmesinde temel kaynak olmuştur.
2. **Predicting Electric Vehicle Charging Station Availability Using Ensemble Machine Learning (2021) [2]:** Takvimsel değişkenler ve geçmiş doluluk verilerini

Gradient Boosting ve Random Forest ile işleyerek istasyonların ertesi günkü boş/dolu durumunu sınıflandırma yaklaşımıyla tahmin etmiştir.

3. **Multistep Electric Vehicle Charging Station Occupancy Prediction Using Hybrid LSTM Neural Networks (2022) [3]:** Dundee açık verisinde geçmiş doluluk serileri ile takvim özelliklerini hibrit LSTM mimarisine besleyerek çok adımlı ikili (boş/dolu) doluluk durumunu sınıflandırma yaklaşımıyla öngörmüştür.
4. **Forecasting Charging Point Occupancy Using Supervised Learning Algorithms (2022) [4]:** ACN-Data üzerinde denetimli öğrenme modellerini geçmiş doluluk durumları ve takvim öznitelikleriyle eğiterek nokta ve saha bazında kısa vadeli doluluk tahmini yapmıştır.
5. **Data-Driven, Short-Term Prediction of Charging Station Occupation (2023) [5]:** Almanya'daki 2.079 istasyona ait 4.602 hızlı şarj konnektörünün geçmiş şarj verileriyle, Random Forest ağaçlarının tahminlerini devam eden şarj oturumlarının anlık bilgileriyle birleştiren bir yöntem önermiş; şarj sürelerini gerçek zamanlı tahmin ederek dolu istasyonlarda bekleme süresini öngörmüş ve bu yöntemin Random Forest ile LightGBM modellerinden daha iyi sonuç verdiğini göstermiştir.
6. **Machine Learning-Based Electric Vehicle Charging Demand Forecasting: A Systematized Literature Review (2025) [6]:** Makine öğrenmesi tabanlı şarj talebi tahmini literatürünü sistematik olarak tarayarak çalışmaları kullanılan yönteme (makine öğrenmesi, derin öğrenme ve hibrit yaklaşımlar) ve şarj uygulaması türüne göre sınıflandırmış; derin öğrenmeye doğru belirgin bir yönelim olduğunu ve çalışmalar arasında standart performans metriklerinin eksik olduğunu tespit etmiştir.
7. **Electric Vehicles Charging Stations Load Forecasting Based on Hybrid XGBoost-BiLSTM Model (2026) [7]:** ACN-Caltech veri setindeki 31.424 şarj oturumunu (temizleme sonrası 14.496) kullanarak hibrit XGBoost-BiLSTM yığınlama (stacking) modeliyle istasyon düzeyinde saatlik şarj yükü tahmini yapmış, modeli 24 alternatif modelle kıyaslamış ve hava durumu ile elektrik fiyatı gibi dışsal değişkenlerin kullanılmamasını çalışmanın sınırlılığı olarak belirtmiştir.
8. **Machine Learning Approaches to Short-Term Electric Vehicle Charging Demand Prediction: Applicability and Geographical Transferability (2026) [8]:** Farklı ülkelerdeki 12 senaryoda altı makine öğrenmesi modelini kıyaslayarak geliştirilen tahmin sistemlerinin farklı coğrafi bölgelere aktarılabilirliğini incelemiştir.

Kaynakça

- **[1]** Lee, Z. J., Li, T., & Low, S. H. (2019). ACN-Data: Analysis and Applications of an Open EV Charging Dataset. Proceedings of the Tenth ACM International Conference on Future Energy Systems, 139–149. https://doi.org/10.1145/3307772.3328313
- [2] Hecht, C., Figgener, J., & Sauer, D. U. (2021). Predicting Electric Vehicle Charging Station Availability Using Ensemble Machine Learning. Energies, 14(23), 7834. https://doi.org/10.3390/en14237834
- [3] Ma, T.-Y., & Faye, S. (2022). Multistep electric vehicle charging station occupancy prediction using hybrid LSTM neural networks. Energy, 244, 123217. https://doi.org/10.1016/j.energy.2022.123217
- [4] Ostermann, A., Fabel, Y., Ouan, K., & Koo, H. (2022). Forecasting Charging Point Occupancy Using Supervised Learning Algorithms. Energies, 15(9), 3409. https://doi.org/10.3390/en15093409
- [5] Aghsaee, R., Hecht, C., Schwinger, F., Figgener, J., Jarke, M., & Sauer, D. U. (2023). Data-Driven, Short-Term Prediction of Charging Station Occupation. Electricity, 4(2), 134–153. https://doi.org/10.3390/electricity4020009
- [6] Alaraj, M., Radi, M., Alsisi, E., Majdalawieh, M., & Darwish, M. (2025). Machine Learning-Based Electric Vehicle Charging Demand Forecasting: A Systematized Literature Review. Energies, 18(17), 4779. https://doi.org/10.3390/en18174779
- [7] Mansour, H. S. E., Mohamed, A. S., & Abdel-Aziz, M. (2026). Electric vehicles charging stations load forecasting based on hybrid XGBoost-BiLSTM model. Scientific Reports, 16, 374. https://doi.org/10.1038/s41598-025-29739-z
- [8] Wang, S., Bu, Y., Wei, B., Cao, E., Ma, R., & Zhuge, C. (2026). Machine learning approaches to short-term electric vehicle charging demand prediction: Applicability and geographical transferability. Journal of Energy Storage, 163, 122141. https://doi.org/10.1016/j.est.2026.122141